

Deteksi Penggunaan Ponsel Pengemudi pada Citra Multi-View dengan EfficientNetV2 dan Decision-Level Fusion

Proposal Tugas Akhir

(IF-47-DSIS.05)

103012300148

Muhammad Akhdan Ghifari



Program Studi Sarjana Informatika

Fakultas Informatika

Universitas Telkom

Bandung

2026

Lembar Persetujuan

Deteksi Penggunaan Ponsel Pengemudi pada Citra Multi-View
dengan EfficientNetV2 dan Decision-Level Fusion

*Multi-View Image-Based Driver Mobile Phone Usage Detection
Using EfficientNetV2 and Decision-Level Fusion*

NIM: 103012300148
Muhammad Akhdan Ghifari

Proposal ini diajukan sebagai usulan pembuatan tugas akhir pada
Program Studi Sarjana Informatika
Fakultas Informatika Universitas Telkom

Bandung, 25 Mei 2026
Menyetujui

Pembimbing 1

Pembimbing 2

Dr. Untari Novia Wisesty,
S.T., M.T.
NIP: 13870083

Dr. I Wayan Palton Anuwiksa,
S.Si., M.Si.
NIP: 23950001

Abstrak

Penggunaan ponsel saat mengemudi merupakan salah satu bentuk distraksi yang berisiko karena dapat mengurangi perhatian visual dan kognitif pengemudi, sedangkan sistem deteksi berbasis *single-view* masih rentan terhadap oklusi ketika sebagian tubuh, tangan, atau perangkat ponsel tidak terlihat jelas dari satu sudut pandang kamera. Penelitian ini bertujuan untuk menganalisis perbedaan performa dan pola kegagalan deteksi antara *front view* dan *side view*, mengevaluasi efektivitas pendekatan *multi-view* dibandingkan sistem *single-view* terbaik, serta membandingkan strategi *average fusion* dan *adaptive fusion* pada tingkat *decision-level*. Penelitian ini menggunakan dataset publik 3MDAD dengan modalitas citra RGB siang hari dari dua sudut pandang tersinkronisasi, yaitu *front view* dan *side view*. Tugas klasifikasi dirumuskan sebagai klasifikasi biner antara kelas *safe driving* (A1) dan *phone-use distracted driving* (A5–A9), sehingga penelitian ini tidak bertujuan membedakan seluruh jenis distraksi pengemudi, melainkan secara khusus mendeteksi aktivitas penggunaan ponsel terhadap kondisi mengemudi aman. Model *single-view* dibangun menggunakan EfficientNetV2-S yang diinisialisasi dengan bobot pra-latih ImageNet dan dilatih melalui skema *fine-tuning*. Skor probabilitas kelas *phone-use distracted driving* dari kedua sudut pandang kemudian digabungkan menggunakan *average fusion* dan *adaptive fusion*. Hipotesis awal penelitian ini adalah bahwa pendekatan *multi-view*, khususnya dengan *adaptive fusion*, berpotensi meningkatkan performa klasifikasi karena mampu menyesuaikan kontribusi setiap sudut pandang berdasarkan tingkat keyakinan prediksi. Namun, efektivitas pendekatan tersebut tetap perlu dibuktikan secara empiris karena tingkat keyakinan model tidak selalu berbanding lurus dengan kebenaran prediksi.

Kata Kunci: deteksi distraksi pengemudi, *multi-view fusion*, *decision-level fusion*, EfficientNetV2-S, 3MDAD.

Daftar Isi

Abstrak	i
Daftar Isi	ii
Daftar Gambar	iv
Daftar Tabel	v
I Pendahuluan	1
1.1 Latar Belakang	1
1.2 Perumusan Masalah	4
1.3 Tujuan	4
1.4 Batasan Masalah	4
1.5 Rencana Kegiatan	5
1.6 Jadwal Kegiatan	7
II Kajian Pustaka	8
2.1 Penelitian Terdahulu dan Celah Penelitian	8
2.2 Deteksi Distraksi Pengemudi	10
2.3 Dataset 3MDAD	11
2.4 Oklusi pada Pemantauan Pengemudi	13
2.5 Pendekatan <i>Single-View</i> dan <i>Multi-View</i>	13
2.6 EfficientNetV2 sebagai Backbone	14
2.7 Metrik Evaluasi	16
2.7.1 Akurasi	17
2.7.2 Presisi	17
2.7.3 Recall	17
2.7.4 <i>Macro F1-Score</i>	18
III Perancangan Sistem	19
3.1 Alur Penelitian dan Perancangan Sistem	19
3.2 Pengumpulan dan Prapemrosesan Data	21
3.2.1 Pengumpulan Data dan Perumusan Label	21
3.2.2 Pembagian Dataset	23

3.2.3	Prapemrosesan Citra	24
3.3	Model <i>Single-View</i> Berbasis EfficientNetV2-S	24
3.3.1	Konfigurasi EfficientNetV2-S dan <i>Classifier Head</i>	24
3.3.2	Skema <i>Transfer Learning</i> dan <i>Fine-Tuning</i>	25
3.3.3	Pelatihan dan Keluaran Model <i>Single-View</i>	25
3.3.4	Algoritma Sistem	26
3.4	Strategi <i>Decision-Level Fusion</i>	28
3.4.1	<i>Average Fusion</i>	28
3.4.2	<i>Adaptive Fusion</i>	28
3.5	Skenario Pengujian dan Evaluasi	29
3.5.1	Skenario Pengujian	29
3.5.2	Metrik Evaluasi	30
Daftar Pustaka		32
Lampiran		35

Daftar Gambar

2.1	Perbandingan struktur MBConv dan Fused-MBConv pada EfficientNetV2	15
3.1	Diagram alir perancangan sistem	20
3.2	Contoh citra dari dataset 3MDAD yang digunakan dalam penelitian ini	22

Daftar Tabel

1.1	Jadwal kegiatan tugas akhir	7
2.1	Ringkasan penelitian terdahulu dan celah penelitian	8
2.2	Jumlah <i>frame</i> per kelas aktivitas pada dataset 3MDAD	12
3.1	Distribusi label biner pada data yang digunakan	22
3.2	Rencana pembagian dataset menggunakan <i>subject-based split</i> . .	23

Bab I

Pendahuluan

Bab ini menguraikan latar belakang penelitian yang mencakup permasalahan deteksi penggunaan ponsel oleh pengemudi, keterbatasan pendekatan *single-view*, serta celah penelitian pada strategi *fusion* dalam sistem *multi-view*. Selanjutnya dirumuskan masalah dan tujuan yang ingin dicapai, diikuti dengan batasan masalah, serta rencana dan jadwal kegiatan pelaksanaan penelitian.

1.1 Latar Belakang

Isu keselamatan di jalan raya senantiasa menjadi fokus utama secara global, mengingat tingginya angka kecelakaan yang terjadi. Salah satu faktor penyumbang kecelakaan adalah hilangnya konsentrasi pengemudi (*distracted driving*), yang salah satunya dapat disebabkan oleh interaksi dengan telepon seluler. Secara spesifik, pengemudi yang terdistraksi oleh ponsel cenderung merespons situasi lebih lambat, kehilangan fokus visual, dan kesulitan mengendalikan laju kendaraan [1, 2]. Kondisi tersebut dapat meningkatkan risiko terjadinya kecelakaan atau tabrakan di jalan [1–3]. Untuk memitigasi bahaya ini, teknologi visi komputer (*computer vision*) kini banyak dieksplorasi sebagai mekanisme pengawasan otomatis. Melalui kamera yang terpasang di dalam kabin, sistem cerdas ini dapat mengekstrak informasi visual pengemudi dan mengenali berbagai tindakan berisiko secara langsung pada waktu nyata (*real-time*) [3, 4].

Sejumlah penelitian deteksi distraksi atau penggunaan ponsel oleh pengemudi masih banyak dirancang dengan pendekatan *single-view*, yaitu hanya memanfaatkan satu kamera dari sudut pandang tunggal [5–8]. Namun demikian, penerapan sistem ini di kondisi nyata menghadapi tantangan mendasar berupa oklusi, yaitu kondisi ketika sebagian area tubuh, tangan, atau perangkat ponsel pengemudi tidak terlihat secara jelas akibat komponen interior kendaraan, pergerakan tubuh, atau keterbatasan sudut pandang kamera. Oklusi dapat menyebabkan hilangnya sebagian informasi visual yang dibutuhkan dalam proses klasifikasi [9, 10]. Keterbatasan ini membuat sistem *single-view* rentan terhadap situasi berkendara nyata, misalnya saat pengemudi mencon-

dongkan tubuh, menggerakkan tangan ke posisi tertentu, atau terhalang oleh setir dan sandaran kursi.

Studi terkini mulai mengadopsi pendekatan *multi-view* dengan memanfaatkan beberapa perspektif kamera di dalam kabin, seperti *dashboard*, *rearview mirror*, dan *right-side window*, sebagai sumber informasi komplementer [10,11]. Pendekatan ini dilandasi oleh karakteristik sudut pandang maupun modalitas yang berbeda, yang dapat memiliki keunggulan dan kelemahan saling melengkapi (*complementary advantages*) dalam kondisi oklusi yang bervariasi. Oleh karena itu, penggabungan informasi dari berbagai sumber visual berpotensi meningkatkan ketahanan sistem [11–13]. Sejalan dengan hal ini, Vijeikis dkk. [14] menunjukkan bahwa algoritma fusi *multi-task* yang dirancang untuk sistem pemantauan pengemudi mampu meningkatkan performa deteksi dibandingkan pendekatan *single-task*.

Dalam strategi *decision-level fusion*, *average fusion* merupakan salah satu pendekatan sederhana yang menggabungkan *output* prediksi dari setiap sumber dengan bobot yang sama rata. Meskipun sederhana, pendekatan ini tidak mempertimbangkan perbedaan kualitas informasi visual yang masuk akibat oklusi, sehingga kontribusi setiap kamera diberikan secara setara tanpa menilai tingkat keyakinan prediksinya. Studi empiris sistematis oleh Roitberg dkk. [15] menunjukkan bahwa *average fusion* tidak selalu menjadi pilihan yang paling optimal, karena strategi lain seperti *product-fusion* dan *max-fusion* dapat memberikan performa lebih baik pada beberapa skenario evaluasi.

Selain keterbatasan pada strategi *fusion* statis tersebut, beberapa studi *multi-view* pada pemantauan pengemudi lebih banyak menekankan peningkatan performa akhir atau perancangan mekanisme fusi, misalnya melalui fusi tingkat fitur maupun mekanisme *attention* [10,11]. Berdasarkan kajian tersebut, pembahasan yang secara khusus membedah pola kegagalan (*failure pattern*) dari masing-masing sudut pandang secara terpisah, misalnya kondisi ketika *front view* gagal akibat oklusi alami dan bagaimana *side view* dapat memberikan informasi komplementer, masih belum menjadi fokus utama. Celah ini penting untuk dikaji karena analisis per sudut pandang dapat membantu menjelaskan kapan pendekatan *multi-view* benar-benar efektif maupun terbatas dalam menghadapi kondisi oklusi.

Sebagai alternatif, *adaptive fusion* menawarkan mekanisme pembobotan dinamis yang menyesuaikan kontribusi setiap kamera berdasarkan tingkat keyakinan prediksinya. Secara umum, pendekatan ini memberikan kontribusi yang berbeda pada setiap sumber informasi berdasarkan tingkat keyakinan prediksi atau kualitas informasi yang dihasilkan [16]. Dengan mekanisme tersebut, sumber dengan prediksi yang lebih meyakinkan dapat memberikan pengaruh yang lebih besar terhadap keputusan akhir sistem. Namun, efektivitas pendekatan ini tetap perlu diuji secara empiris karena tingkat keyakinan model tidak selalu berbanding lurus dengan kebenaran prediksi.

Di sisi lain, perbandingan langsung antara *average fusion* dan *adaptive fusion*, khususnya pada kasus deteksi penggunaan ponsel oleh pengemudi dengan menggunakan dataset yang sama dan konfigurasi yang setara, masih relatif jarang dikaji secara sistematis dalam literatur yang ada.

Guna menjawab kesenjangan tersebut, penelitian ini mengusulkan pendekatan *multi-view* berbasis *deep learning* menggunakan dataset 3MDAD (*Multiview, Multimodal and Multispectral Driver Action Dataset*) [9]. Dataset ini dipilih karena menyediakan rekaman naturalistik pengemudi dari dua sudut kamera, yaitu depan dan samping, yang diambil secara tersinkronisasi dalam kondisi berkendara nyata. Dengan karakteristik tersebut, 3MDAD menjadi dataset yang sesuai untuk menganalisis perilaku sistem *multi-view* di bawah kondisi oklusi alami. Dari keseluruhan 16 kelas aksi yang tersedia dalam 3MDAD, penelitian ini berfokus pada kelas penggunaan ponsel (*mobile phone use*). Pemilihan ini didasarkan pada tingkat risiko yang tinggi terhadap keselamatan berkendara, di mana penggunaan ponsel telah dilaporkan sebagai salah satu bentuk distraksi visual dan kognitif yang dapat meningkatkan risiko kecelakaan lalu lintas [1–3]. Selain itu, kategori ini memiliki basis literatur yang kuat dalam konteks deteksi berbasis visi komputer [1–4].

Secara karakteristik, aktivitas penggunaan ponsel berpotensi menimbulkan keterbatasan informasi visual dari sudut pandang tertentu, misalnya ketika tangan menutupi sebagian area tubuh atau perangkat ponsel tidak terlihat jelas dari kamera tunggal [9,10]. Hal ini menjadikan kelas penggunaan ponsel sebagai kasus yang relevan untuk menguji efektivitas pendekatan *multi-view* dalam menghadapi keterbatasan informasi visual.

EfficientNetV2 digunakan sebagai *backbone* pada model klasifikasi *single-view* karena dikenal memiliki keseimbangan yang baik antara akurasi dan efisiensi komputasi [17]. Kebutuhan akan arsitektur yang ringan pada sistem deteksi distraksi pengemudi telah menjadi perhatian aktif dalam literatur [18], memperkuat argumen bahwa efisiensi *backbone* penting agar beban komputasi sistem tetap terkendali, sehingga evaluasi dapat lebih difokuskan pada kontribusi sudut pandang dan strategi fusi. Secara khusus, Lv dkk. [16] menunjukkan bahwa mekanisme fusi adaptif berbasis pembobotan skor dinamis (ATFM) dengan EfficientNetV2 mampu meningkatkan akurasi dari 87,16% pada *average fusion* menjadi 88,35% pada tugas pemantauan pengemudi berbasis video. Namun, pendekatan tersebut menerapkan fusi adaptif pada dimensi temporal, yaitu antar-*frame* dalam satu kamera, untuk mendeteksi kelelahan pengemudi. Berdasarkan hal tersebut, penelitian ini mengevaluasi kemungkinan penerapan prinsip fusi adaptif ke dalam dimensi spasial, yaitu untuk menggabungkan prediksi dari sudut pandang kamera yang berbeda melalui *multi-view decision-level fusion*. Mekanisme *adaptive fusion* pada penelitian ini tidak dimaksudkan sebagai replikasi penuh ATFM, melainkan sebagai adaptasi prinsip pembobotan berbasis tingkat keyakinan prediksi untuk penggabungan skor antar sudut

pandang. Dengan demikian, kontribusi penelitian ini tidak terletak pada pengembangan arsitektur *backbone* baru, melainkan pada evaluasi strategi fusi dan analisis kontribusi sudut pandang dalam mendeteksi penggunaan ponsel oleh pengemudi.

1.2 Perumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, penelitian ini merumuskan permasalahan terkait deteksi penggunaan ponsel oleh pengemudi menggunakan pendekatan *multi-view* sebagai berikut:

1. Seberapa besar perbedaan performa deteksi antara *front view* dan *side view* secara terpisah dalam membedakan kondisi *safe driving* dan *phone-use distracted driving*, serta pola kegagalan deteksi seperti apa yang dapat diidentifikasi melalui hasil evaluasi, *confusion matrix*, dan sampel salah klasifikasi pada masing-masing sudut pandang?
2. Apakah pendekatan *multi-view* memberikan peningkatan performa dibandingkan sistem *single-view* terbaik dalam membedakan kondisi *safe driving* dan *phone-use distracted driving* menggunakan dataset 3MDAD?
3. Strategi *fusion* manakah yang lebih efektif antara *average fusion* dan *adaptive fusion* pada tingkat *decision-level* dalam meningkatkan performa klasifikasi antara *safe driving* dan *phone-use distracted driving*?

1.3 Tujuan

Berdasarkan rumusan masalah tersebut, tujuan dari penelitian ini adalah sebagai berikut:

1. Menganalisis perbedaan performa dan pola kegagalan deteksi antara *front view* dan *side view* dalam membedakan kondisi *safe driving* dan *phone-use distracted driving*.
2. Mengevaluasi efektivitas pendekatan *multi-view* dibandingkan dengan sistem *single-view* terbaik dalam membedakan kondisi *safe driving* dan *phone-use distracted driving*.
3. Membandingkan efektivitas strategi *average fusion* dan *adaptive fusion* pada tingkat *decision-level* dalam meningkatkan performa klasifikasi antara *safe driving* dan *phone-use distracted driving*.

1.4 Batasan Masalah

Agar pembahasan tetap terarah dan sesuai dengan ruang lingkup penelitian, batasan masalah dalam penelitian ini adalah sebagai berikut:

1. Penelitian ini dibatasi pada klasifikasi biner antara *safe driving* dan *phone-use distracted driving* menggunakan dataset 3MDAD.
2. Sudut pandang kamera yang digunakan dibatasi pada dua *view*, yaitu *front view* dan *side view*.
3. Model klasifikasi *single-view* yang digunakan berbasis EfficientNetV2 sebagai *backbone*, tanpa melakukan eksplorasi atau perbandingan dengan arsitektur *backbone* lainnya.
4. Strategi *fusion* yang dibandingkan dibatasi pada *average fusion* dan *adaptive fusion* pada tingkat *decision-level*.
5. Evaluasi performa model dilakukan menggunakan metrik akurasi, presisi, *recall*, dan *Macro F1-Score*.

1.5 Rencana Kegiatan

Rencana kegiatan dalam penelitian ini terdiri dari enam tahapan utama yang disusun secara sistematis untuk memastikan ketercapaian tujuan penelitian.

1. Studi Literatur

Tahap ini bertujuan untuk memahami konsep dasar terkait deteksi distraksi pengemudi, pendekatan *multi-view*, serta strategi *fusion* seperti *average fusion* dan *adaptive fusion*. Selain itu, dilakukan kajian terhadap penelitian-penelitian terdahulu untuk mengidentifikasi kesenjangan penelitian yang menjadi dasar perumusan masalah. Studi literatur dilakukan secara berkelanjutan sepanjang pelaksanaan penelitian.

2. Pengumpulan Data

Tahap ini mencakup pengunduhan dan verifikasi dataset 3MDAD, khususnya data rekaman dari dua sudut pandang kamera (*front view* dan *side view*) pada kelas *safe driving* (A1) dan *phone-use distracted driving* (A5–A9). Selain itu, dilakukan prapemrosesan data yang meliputi ekstraksi *frame*, normalisasi citra, serta pembagian dataset menjadi data latih, validasi, dan uji dengan proporsi yang sesuai.

3. Analisis dan Perancangan Sistem

Pada tahap ini dilakukan analisis kebutuhan sistem dan perancangan arsitektur model secara menyeluruh. Perancangan mencakup pemilihan konfigurasi model klasifikasi *single-view* berbasis EfficientNetV2, perancangan alur pelatihan model untuk masing-masing sudut pandang secara

terpisah, serta perancangan mekanisme *decision-level fusion* untuk pendekatan *multi-view* dengan dua strategi yang akan dibandingkan, yaitu *average fusion* dan *adaptive fusion*.

4. Implementasi Sistem

Tahap ini mencakup implementasi model klasifikasi berbasis Efficient-NetV2 untuk *front view* dan *side view* secara terpisah, diikuti dengan proses *fine-tuning*, pelatihan, dan validasi masing-masing model. Selanjutnya diimplementasikan mekanisme *decision-level fusion* dengan kedua strategi yang dirancang, yaitu *average fusion* dan *adaptive fusion*. Hasil implementasi ini digunakan untuk mengevaluasi model *single-view* dari masing-masing sudut pandang, menentukan sistem *single-view* terbaik, serta membandingkannya dengan pendekatan *multi-view*.

5. Analisis Hasil Implementasi

Evaluasi dilakukan terhadap model *single-view* dari masing-masing sudut pandang serta pendekatan *multi-view* dengan *average fusion* dan *adaptive fusion* menggunakan metrik akurasi, presisi, *recall*, dan *Macro F1-Score*.

6. Penulisan Laporan

Tahap ini mencakup penyusunan laporan tugas akhir secara menyeluruh, meliputi pendahuluan, kajian pustaka, metodologi, hasil dan pembahasan, serta kesimpulan dan saran. Penulisan laporan dilakukan secara paralel sejak tahap analisis dan perancangan sistem hingga selesainya seluruh kegiatan penelitian.

1.6 Jadwal Kegiatan

Jadwal pelaksanaan Tugas Akhir ini disusun secara sistematis berdasarkan tahapan pada rencana kegiatan yang telah diuraikan sebelumnya. Rincian alokasi waktu untuk masing-masing tahapan, mulai dari studi literatur hingga penulisan laporan, disajikan pada tabel berikut guna memastikan penelitian dapat diselesaikan dengan terstruktur dan sesuai target waktu.

Tabel 1.1: Jadwal kegiatan tugas akhir

No	Kegiatan	Bulan ke-																									
		1				2				3				4				5				6					
1	Studi Literatur																										
2	Pengumpulan Data																										
3	Analisis dan Perancangan Sistem																										
4	Implementasi Sistem																										
5	Analisis Hasil Implementasi																										
6	Penulisan Laporan																										

Bab II

Kajian Pustaka

Bab ini memuat kajian terhadap penelitian-penelitian terdahulu dan teori pendukung yang relevan dengan topik deteksi penggunaan ponsel oleh pengemudi berbasis pendekatan *multi-view*. Kajian pustaka disusun untuk menunjukkan posisi penelitian, landasan ilmiah yang digunakan, serta celah penelitian yang menjadi dasar pengembangan penelitian ini.

2.1 Penelitian Terdahulu dan Celah Penelitian

Bagian ini merangkum penelitian-penelitian terdahulu yang relevan dengan topik penelitian, beserta celah (*research gap*) yang menjadi dasar usulan penelitian ini. Ringkasan perbandingan disajikan pada Tabel 2.1.

Tabel 2.1: Ringkasan penelitian terdahulu dan celah penelitian

Referensi (Tahun)	Dataset & Sudut Pandang	Metode	Fokus Penelitian	Relevansi & Celah
Lv dkk. (2024) [16]	NTHU-DDD (<i>Single-view</i>)	EfficientNetV2 + <i>adaptive temporal fusion</i>	Menunjukkan bahwa fusi adaptif (ATFM) dengan EfficientNetV2 mampu mengungguli <i>average fusion</i> pada tugas deteksi kelelahan berbasis video.	Relevansi: Acuan prinsip fusi adaptif berbasis tingkat keyakinan prediksi dengan EfficientNetV2. Celah: Hanya diuji pada dimensi <i>temporal</i> antar-frame dalam satu kamera, sedangkan penelitian ini mengadaptasi prinsip tersebut pada dimensi spasial lintas-kamera (<i>multi-view</i>).

Referensi (Tahun)	Dataset & Sudut Pandang	Metode	Fokus Penelitian	Relevansi & Celah
Roitberg dkk. (2022) [15]	Drive&Act (<i>Multimodal, 8 modalitas</i>)	I3D CNN + berbagai strategi <i>decision-level</i>	Evaluasi sistematis terhadap berbagai strategi <i>decision-level fusion</i> ; menunjukkan bahwa <i>average fusion</i> tidak selalu menjadi strategi terbaik karena <i>product-fusion</i> dan <i>max-fusion</i> dapat memberikan performa lebih baik pada beberapa skenario evaluasi.	Relevansi: Landasan empiris keterbatasan <i>average fusion</i> sebagai strategi <i>decision-level</i> standar. Celah: Menguji fusi lintas-modalitas sensor berbeda, bukan lintas sudut pandang kamera RGB; tidak membedakan pola kegagalan per sudut pandang.
Kuang dkk. (2023) [11]	3MDAD (<i>Multi-view</i>)	I3D / ResNet + <i>feature-level fusion</i>	Menunjukkan pendekatan <i>multi-view</i> lebih kokoh dalam mengatasi oklusi.	Relevansi: <i>Baseline</i> keunggulan <i>multi-view</i> pada 3MDAD. Celah: Fusi dilakukan pada tingkat fitur, bukan pada tingkat keputusan (<i>decision-level</i>).
Jegham dkk. (2020) [9]	3MDAD (<i>Front+Side</i>)	ResNet / VGG + <i>early fusion</i>	Memperkenalkan dataset naturalistik dua sudut pandang simultan pada lingkungan dinamis.	Relevansi: Sumber data dan acuan eksperimen utama. Celah: <i>Baseline</i> asli belum mengeksplorasi <i>decision-level fusion</i> tingkat lanjut.
Duan dkk. (2025) [19]	SFDDD, AUCDD & 100-Driver (<i>Cross-dataset</i>)	CNN + <i>Score-Softmax</i> (S-Softmax) + <i>Gaussian Fusion</i>	Meningkatkan performa lintas-dataset dengan S-Softmax classifier dan Dynamic Gaussian Smoothing, disertai strategi fusi multi-saluran berbasis distribusi Gaussian.	Relevansi: Mendukung pentingnya pengolahan skor keluaran klasifikasi di tingkat keputusan untuk meningkatkan robustitas prediksi. Celah: Fokus pada permasalahan <i>background noise</i> dan generalisasi lintas-dataset, bukan kondisi oklusi akibat variasi sudut pandang kamera pada 3MDAD.

Referensi (Tahun)	Dataset & Sudut Pandang	Metode	Fokus Penelitian	Relevansi & Celah
Hsia dkk. (2026) [10]	SynDD1 & DMD (Multi-view)	Temporal GCN + adaptive attention	Menunjukkan bahwa oklusi membuat <i>single-view</i> rentan, sehingga mekanisme <i>multi-view attention</i> dibutuhkan.	Relevansi: Memperkuat argumen kerentanan oklusi pada <i>single-view</i> . Celah: Menggunakan pendekatan berbasis <i>graph</i> dan <i>attention</i> untuk <i>multi-view behavior recognition</i> , sedangkan penelitian ini berfokus pada klasifikasi citra RGB dengan <i>decision-level fusion</i> berbasis skor probabilitas.
Duan dkk. (2023) [18]	SFD, AUCDD-V1 & 3MDAD (Single-view)	FRNet (lightweight DCNN)	Merancang arsitektur DCNN ringan untuk deteksi distraksi secara <i>real-time</i> pada perangkat <i>embedded</i> tanpa GPU.	Relevansi: Justifikasi kebutuhan ekstraktor fitur efisien pada sistem deteksi distraksi. Celah: Hanya untuk <i>single-view</i> , tidak memperhitungkan fusi lintas kamera.

Berdasarkan kajian pada Tabel 2.1, terdapat tiga celah utama yang menjadi landasan penelitian ini. *Pertama*, studi yang menjadikan pola kegagalan deteksi dari masing-masing sudut pandang (*front view* dan *side view*) sebagai fokus analisis utama pada dataset 3MDAD masih terbatas. Oleh karena itu, kontribusi komplementer tiap kamera dalam kondisi oklusi alami masih perlu dibuktikan secara empiris. *Kedua*, meskipun *adaptive fusion* telah menunjukkan performa yang lebih baik dibandingkan *average fusion* pada dimensi temporal [16], penerapannya pada dimensi spasial lintas-kamera (*multi-view decision-level fusion*) untuk kasus penggunaan ponsel pengemudi masih perlu dikaji lebih lanjut. *Ketiga*, beberapa studi *multi-view* yang ada berfokus pada fusi tingkat fitur [11] atau menggunakan pendekatan berbasis *graph* dan *attention* [10], sehingga evaluasi berbasis citra RGB dengan strategi *decision-level fusion* adaptif pada 3MDAD masih terbuka untuk dikaji. Penelitian ini berupaya mengisi celah tersebut dengan mengombinasikan analisis per-view, perbandingan *average fusion* dan *adaptive fusion* pada tingkat keputusan, serta penggunaan EfficientNetV2 sebagai *backbone* agar evaluasi strategi fusi dapat dilakukan secara lebih terarah.

2.2 Deteksi Distraksi Pengemudi

Distraksi pengemudi merupakan kondisi ketika perhatian pengemudi teralihkan dari tugas utama dalam mengemudi. Salah satu bentuk distraksi yang paling berisiko adalah penggunaan ponsel saat berkendara karena dapat mengurangi fokus visual, memperlambat waktu reaksi, dan menurunkan kemampuan

an pengambilan keputusan. Tan dkk. [1] mencatat bahwa faktor manusia diperkirakan menjadi penyebab sekitar 90% kecelakaan jalan, dengan perilaku berbahaya pengemudi berkontribusi sekitar 68% dari keseluruhan statistik tersebut. Lebih lanjut, Tan dkk. [1] menjelaskan bahwa deteksi perilaku distraksi pengemudi telah berkembang melalui berbagai pendekatan, mulai dari metode berbasis citra, video, sensor multimodal, hingga pembelajaran mendalam. Koay dkk. [2] juga menegaskan bahwa perkembangan metode deteksi distraksi pengemudi sangat dipengaruhi oleh ketersediaan dataset, kompleksitas kondisi kabin kendaraan, serta tantangan variasi sudut pandang dan pencahayaan.

Pada konteks penggunaan ponsel, Huang dkk. [3] mengusulkan metode deteksi penggunaan ponsel pengemudi menggunakan *guided learning* berbasis *attention features* dan *prior knowledge*. Pendekatan ini memanfaatkan anotasi area perhatian pada citra pengemudi serta pengetahuan yang diperoleh dari dataset klasifikasi lain sebagai bobot awal, sehingga meningkatkan akurasi dan kemampuan generalisasi model deteksi pada kondisi data latih yang terbatas.

2.3 Dataset 3MDAD

Penelitian ini menggunakan dataset 3MDAD (*Multiview, Multimodal and Multispectral Driver Action Dataset*) sebagai sumber data utama. Dataset ini diperkenalkan oleh Jegham dkk. [9] sebagai dataset publik untuk analisis perilaku dan distraksi pengemudi dalam lingkungan berkendara nyata (*naturalistic driving settings*). Dataset 3MDAD dirancang dengan karakteristik *multi-view*, *multimodal*, dan *multispectral*, sehingga memungkinkan penelitian terhadap berbagai kondisi pencahayaan, sudut pandang, dan modalitas citra pengemudi.

Dataset 3MDAD terdiri dari dua subset berdasarkan kondisi pencahayaan, yaitu subset siang hari (*daytime*) dan malam hari (*nighttime*). Pada subset siang hari, dataset menyediakan *frame* RGB dan *frame* kedalaman (*depth*) yang tersinkronisasi secara temporal dengan laju akuisisi 30 Hz dan resolusi 640×480 piksel. Sementara itu, subset malam hari menyediakan *frame* inframerah (*infrared*) dan *frame* kedalaman dengan resolusi yang sama [9].

Akuisisi data dilakukan menggunakan dua kamera Microsoft Kinect. Kamera pertama dipasang pada pegangan mobil di bagian atas jendela penumpang untuk memperoleh sudut pandang samping (*side view*), sedangkan kamera kedua dipasang pada dasbor di depan pengemudi untuk memperoleh sudut pandang depan (*front view*). Penggunaan dua kamera tersebut memungkinkan pengambilan data dari beberapa sudut pandang secara simultan sehingga membantu mengurangi permasalahan oklusi dan memberikan representasi aktivitas pengemudi yang lebih lengkap [9].

Subset siang hari melibatkan 50 partisipan yang terdiri dari 38 laki-laki dan 12 perempuan dengan rentang usia 19 hingga 41 tahun. Sementara itu, subset malam hari melibatkan 19 partisipan lain yang terdiri dari 11 laki-laki dan

8 perempuan dengan rentang usia 19 hingga 53 tahun [9]. Setiap partisipan diminta untuk melakukan 16 aktivitas di dalam kendaraan selama sekitar 20 hingga 35 detik untuk setiap aktivitas, menghasilkan sekitar 1.104 sekuens secara keseluruhan, yaitu 800 sekuens pada siang hari dan 304 sekuens pada malam hari. Total durasi rekaman mencapai sekitar 507 menit [9].

Dataset ini mencakup 16 kelas aktivitas pengemudi yang umum dilakukan selama berkendara, yaitu: (A1) *safe driving*, (A2) *doing hair and makeup*, (A3) *adjusting radio*, (A4) *GPS operating*, (A5) *writing message using right hand*, (A6) *writing message using left hand*, (A7) *talking phone using right hand*, (A8) *talking phone using left hand*, (A9) *having picture*, (A10) *talking to passenger*, (A11) *singing or dancing*, (A12) *fatigue and somnolence*, (A13) *drinking using right hand*, (A14) *drinking using left hand*, (A15) *reaching behind*, dan (A16) *smoking* [9].

Jumlah *frame* untuk masing-masing kelas aktivitas pada subset siang dan malam hari disajikan pada Tabel 2.2. Secara keseluruhan, subset siang hari memuat 444.104 gambar yang mencakup modalitas RGB dan *depth* dari dua sudut pandang, sedangkan subset malam hari memuat 130.028 gambar yang mencakup modalitas inframerah dan *depth* dari dua sudut pandang [9].

Tabel 2.2: Jumlah *frame* per kelas aktivitas pada dataset 3MDAD [9]

Kelas	Aktivitas	Siang	Malam
A1	Safe driving	6.761	1.857
A2	Doing hair and makeup	6.453	2.046
A3	Adjusting radio	6.534	1.803
A4	GPS operating	7.657	2.284
A5	Writing message using right hand	6.337	1.916
A6	Writing message using left hand	6.360	1.864
A7	Talking phone using right hand	7.373	2.130
A8	Talking phone using left hand	7.487	1.987
A9	Having picture	7.256	2.036
A10	Talking to passenger	8.400	2.569
A11	Singing or dancing	7.243	1.951
A12	Fatigue and somnolence	6.843	2.221
A13	Drinking using right hand	6.387	1.861
A14	Drinking using left hand	6.396	1.843
A15	Reaching behind	5.801	1.843
A16	Smoking	7.738	2.296
Total		444.104	130.028

Siang: RGB + *Depth* + *Side view* + *Front view*

Malam: IR + *Depth* + *Side view* + *Front view*

2.4 Oklusi pada Pemantauan Pengemudi

Oklusi (*occlusion*) merupakan kondisi ketika sebagian objek atau bagian tubuh tidak terlihat secara penuh dalam citra akibat terhalang oleh objek lain atau keterbatasan sudut pandang kamera. Dalam konteks pemantauan pengemudi, oklusi dan keterbatasan sudut pandang menjadi tantangan penting pada sistem berbasis kamera [10, 20]. Kondisi ini relevan dengan dataset 3MDAD karena aktivitas pengemudi direkam dari dua sudut pandang yang berbeda, sehingga visibilitas bagian tubuh atau objek yang digunakan pengemudi dapat berbeda antar kamera [9].

Keberadaan oklusi dapat menyebabkan hilangnya sebagian informasi visual yang dibutuhkan dalam proses klasifikasi, sehingga menjadi tantangan bagi sistem deteksi berbasis visi komputer, khususnya ketika sistem hanya mengandalkan satu sudut pandang kamera [9, 10]. Permasalahan ini relevan pada kondisi berkendara nyata karena posisi tubuh pengemudi dan interaksi dengan objek di dalam kendaraan dapat menyebabkan sebagian area tubuh tidak terlihat secara optimal dari sudut pandang kamera tertentu.

Keunggulan dataset 3MDAD terletak pada kemampuannya merepresentasikan kondisi berkendara yang lebih natural dibandingkan dataset dengan satu sudut kamera saja [9]. Hal ini penting karena pada kondisi nyata, informasi visual dari satu sudut pandang saja sering kali tidak cukup untuk menangkap seluruh bagian tubuh atau aktivitas tangan pengemudi secara lengkap. Oleh karena itu, dataset ini sangat sesuai untuk menguji apakah pendekatan *multi-view* benar-benar memberikan keuntungan dibandingkan *single-view* dalam menghadapi kondisi oklusi.

2.5 Pendekatan *Single-View* dan *Multi-View*

Pendekatan *single-view* merupakan metode deteksi yang hanya mengandalkan satu kamera untuk mengamati pengemudi. Pendekatan ini sederhana dan efisien, tetapi rentan terhadap oklusi serta keterbatasan sudut pandang [2, 10]. Pada kondisi tertentu, informasi visual penting seperti tangan, wajah, atau objek yang digunakan pengemudi dapat terhalang oleh setir, posisi tubuh, atau komponen interior kendaraan. Hal ini dapat menyebabkan prediksi model menjadi kurang stabil karena informasi dari satu sudut pandang saja tidak selalu cukup untuk merepresentasikan aktivitas pengemudi secara lengkap. Beberapa penelitian *single-view* berupaya meningkatkan performa melalui mekanisme perhatian, seperti yang dilakukan oleh Xiao dkk. [7] serta Gao dan Liu [8].

Sebaliknya, pendekatan *multi-view* memanfaatkan dua atau lebih sudut pandang untuk memperoleh informasi yang saling melengkapi. Pendekatan ini bertujuan agar kelemahan satu kamera dapat dikompensasi oleh kamera lainnya, terutama pada kondisi oklusi. Kuang dkk. [11] menunjukkan bahwa integrasi informasi dari beberapa kamera dapat meningkatkan ketahanan sis-

tem dalam mengenali aktivitas pengemudi. Temuan serupa juga ditunjukkan oleh Ma dkk. [12], Yang dkk. [13], Xu dkk. [21], dan Mou dkk. [22], yang menekankan bahwa penggabungan informasi atau representasi dari beberapa sumber visual dapat meningkatkan robustitas sistem apabila strategi fusi dirancang dengan tepat.

Dalam konteks dataset 3MDAD, pendekatan *multi-view* direpresentasikan melalui dua sudut kamera utama, yaitu *front view* dan *side view*, yang diambil secara tersinkronisasi [9]. Kedua sudut pandang tersebut memiliki karakteristik visibilitas yang berbeda. *Front view* cenderung menangkap area wajah dan bagian depan tubuh pengemudi, sedangkan *side view* memberikan informasi tambahan terkait posisi tubuh dan pergerakan tangan secara lateral. Perbedaan karakteristik ini membuat kedua sudut pandang berpotensi saling melengkapi dalam mendeteksi aktivitas penggunaan ponsel.

Informasi dari beberapa sudut pandang dalam sistem *multi-view* dapat digabungkan melalui beberapa strategi, salah satunya adalah *decision-level fusion*. Strategi ini menggabungkan skor probabilitas keluaran dari model *single-view* yang telah dilatih secara independen, sehingga masing-masing sudut pandang tetap dapat dievaluasi secara terpisah sebelum hasil prediksinya digabungkan. Pada penelitian ini, strategi *decision-level fusion* yang dibandingkan adalah *average fusion* dan *adaptive fusion*. *Average fusion* memberikan bobot yang sama pada setiap sumber prediksi dan merupakan salah satu strategi *decision-level fusion* yang umum digunakan [15]. Sementara itu, *adaptive fusion* pada penelitian ini dirancang dengan mengadaptasi prinsip pembobotan dinamis berbasis tingkat keyakinan prediksi, yang terinspirasi dari pendekatan fusi adaptif pada domain temporal [16].

2.6 EfficientNetV2 sebagai Backbone

EfficientNetV2 digunakan sebagai *backbone* pada model klasifikasi *single-view* dalam penelitian ini karena memiliki keseimbangan yang baik antara akurasi, efisiensi parameter, dan kecepatan pelatihan. Tan dan Le [17] memperkenalkan EfficientNetV2 sebagai pengembangan dari EfficientNet dengan memanfaatkan *training-aware neural architecture search*, strategi *compound scaling*, serta penggunaan blok *Fused-MBConv* untuk meningkatkan efisiensi pelatihan dan inferensi model.

Pada keluarga EfficientNet, proses penskalaan model dilakukan menggunakan pendekatan *compound scaling* yang diperkenalkan pada EfficientNet generasi pertama [23] dan diadopsi kembali pada EfficientNetV2 [17]. Pendekatan ini secara umum dinyatakan sebagai:

$$d = \alpha^\phi, \quad w = \beta^\phi, \quad r = \gamma^\phi \quad (2.1)$$

dengan syarat penskalaan:

$$\alpha \cdot \beta^2 \cdot \gamma^2 \approx 2 \quad (2.2)$$


dengan d , w , dan r masing-masing menyatakan kedalaman jaringan, lebar jaringan, dan resolusi citra masukan. Parameter ϕ menyatakan koefisien penskalaan (*scaling coefficient*), sedangkan α , β , dan γ merupakan konstanta penskalaan untuk dimensi kedalaman, lebar, dan resolusi [23].

Selain itu, EfficientNetV2 menggunakan fungsi *reward* pada proses *neural architecture search* untuk mempertimbangkan akurasi, efisiensi parameter, dan kecepatan pelatihan secara bersamaan. Fungsi tersebut dinyatakan sebagai:

$$R = A \cdot S^w \cdot P^v \quad (2.3)$$

dengan R menyatakan nilai *reward*, A menyatakan akurasi model, S menyatakan waktu pelatihan yang telah dinormalisasi, dan P menyatakan jumlah parameter model. Parameter $w = -0.07$ dan $v = -0.05$ merupakan konstanta empiris yang digunakan untuk menyeimbangkan kontribusi kecepatan pelatihan dan efisiensi parameter pada proses pencarian arsitektur [17].

EfficientNetV2 juga memperkenalkan penggunaan blok *Fused-MBConv*, yaitu pengembangan dari *MBConv* yang menggabungkan operasi *depthwise convolution* dan *expansion convolution* menjadi satu operasi konvolusi reguler pada tahap awal jaringan untuk meningkatkan efisiensi pelatihan [17]. Perbandingan struktur MBConv dan Fused-MBConv pada EfficientNetV2 ditunjukkan pada Gambar 2.1.



Gambar 2.1: Perbandingan struktur MBConv dan Fused-MBConv pada EfficientNetV2 [17]

Berdasarkan Gambar 2.1, penggunaan *Fused-MBConv* pada tahap awal jaringan bertujuan untuk mengurangi overhead memori dan meningkatkan efi-

siensi komputasi pada perangkat akselerator modern. Pendekatan ini memungkinkan proses pelatihan berlangsung lebih cepat tanpa meningkatkan kompleksitas model secara signifikan [17].

EfficientNetV2 menawarkan keseimbangan antara efisiensi dan kemampuan representasi fitur melalui optimasi struktur jaringan dan strategi pelatihan yang lebih efisien dibandingkan generasi sebelumnya [17]. Dalam konteks deteksi distraksi pengemudi, Khan dkk. [6] menunjukkan bahwa pendekatan berbasis EfficientNetB0 yang diintegrasikan dengan mekanisme perhatian kanal (*channel attention*) mampu mencapai akurasi 99,58% pada dataset *State Farm Distracted Driver Detection* (SFD3) dan 98,97% pada *AUC Distracted Driver* (AUCD2). Hasil tersebut menunjukkan bahwa keluarga EfficientNet layak digunakan sebagai *backbone* yang efisien dan efektif untuk tugas deteksi distraksi pengemudi. Sementara itu, EfficientNetV2 merupakan generasi lanjutan yang dirancang untuk meningkatkan efisiensi pelatihan dan performa model [17].

Beberapa penelitian terdahulu pada dataset 3MDAD memang menggunakan arsitektur seperti ResNet atau VGG sebagai *backbone* maupun bagian dari mekanisme fusi [9,11]. Namun, penelitian ini tidak bertujuan melakukan perbandingan antar-*backbone*, melainkan mengevaluasi kontribusi sudut pandang dan strategi *decision-level fusion* pada skenario klasifikasi *safe driving* dan *phone-use distracted driving*. Oleh karena itu, penggunaan ResNet tidak dijadikan fokus utama agar eksperimen tidak bergeser menjadi studi komparatif arsitektur. EfficientNetV2 dipilih karena memiliki keseimbangan antara akurasi, efisiensi parameter, dan kecepatan pelatihan [17], serta telah digunakan oleh Lv dkk. [16] dalam sistem pemantauan pengemudi berbasis fusi adaptif. Pada penelitian ini, EfficientNetV2-S digunakan secara konsisten pada *front view* dan *side view* agar perbedaan performa yang diamati lebih merepresentasikan pengaruh sudut pandang dan strategi fusi, bukan perbedaan kompleksitas arsitektur *backbone*.

2.7 Metrik Evaluasi

Evaluasi performa model dilakukan menggunakan metrik akurasi, presisi, *recall*, dan *Macro F1-Score*. Perhitungan metrik tersebut didasarkan pada komponen *confusion matrix*, yaitu *true positive* (TP), *true negative* (TN), *false positive* (FP), dan *false negative* (FN) [24]. Karena distribusi kelas pada penelitian ini tidak seimbang, *Macro F1-Score* digunakan sebagai metrik utama. Metrik ini dipilih karena menghitung nilai *F1-Score* pada setiap kelas secara terpisah, kemudian merata-ratakannya sehingga kelas *safe driving* dan *phone-use distracted driving* memiliki kontribusi yang setara dalam evaluasi. Akurasi, presisi, dan *recall* digunakan sebagai metrik pendukung.

2.7.1 Akurasi

Akurasi (*accuracy*) digunakan untuk mengukur proporsi keseluruhan prediksi yang benar terhadap seluruh data pengujian [24]. Nilai akurasi dapat dihitung menggunakan persamaan berikut:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.4)$$

dengan:

- TP : jumlah *true positive*,
- TN : jumlah *true negative*,
- FP : jumlah *false positive*,
- FN : jumlah *false negative*.

Semakin tinggi nilai akurasi, semakin besar proporsi prediksi model yang sesuai dengan label sebenarnya. Namun, akurasi dapat menjadi kurang representatif pada distribusi data yang tidak seimbang karena cenderung dipengaruhi oleh kelas mayoritas [24, 25].

2.7.2 Presisi

Presisi (*precision*) digunakan untuk mengukur tingkat ketepatan model dalam memprediksi kelas positif [24]. Presisi dihitung menggunakan persamaan:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2.5)$$

dengan:

- TP : jumlah *true positive*,
- FP : jumlah *false positive*.

Nilai presisi yang tinggi menunjukkan bahwa sebagian besar data yang diprediksi sebagai penggunaan ponsel memang benar merupakan aktivitas penggunaan ponsel.

2.7.3 Recall

Recall atau sensitivitas digunakan untuk mengukur kemampuan model dalam mendeteksi seluruh data positif yang sebenarnya ada pada dataset [24]. Nilai *recall* dihitung menggunakan persamaan:

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.6)$$

dengan:

- TP : jumlah *true positive*,
- FN : jumlah *false negative*.

Nilai *recall* yang tinggi menunjukkan bahwa model mampu mendeteksi sebagian besar aktivitas penggunaan ponsel yang benar-benar terjadi.

2.7.4 *Macro F1-Score*

F1-Score merupakan rata-rata harmonik antara presisi dan *recall*, sehingga dapat digunakan untuk mengevaluasi keseimbangan performa model terhadap kedua metrik tersebut [24]. Nilai *F1-Score* dihitung menggunakan persamaan:

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (2.7)$$

dengan:

- Precision : nilai presisi,
- Recall : nilai *recall*.

Pada penelitian ini, nilai *F1-Score* yang digunakan sebagai metrik utama adalah *Macro F1-Score*. *Macro F1-Score* dihitung dengan merata-ratakan nilai *F1-Score* dari setiap kelas, sehingga setiap kelas memiliki bobot kontribusi yang sama tanpa dipengaruhi oleh jumlah sampel pada masing-masing kelas. Untuk klasifikasi biner pada penelitian ini, *Macro F1-Score* dihitung sebagai berikut:

$$\text{Macro } F1 = \frac{F1_{safe} + F1_{phone}}{2} \quad (2.8)$$

dengan $F1_{safe}$ menyatakan nilai *F1-Score* untuk kelas *safe driving*, sedangkan $F1_{phone}$ menyatakan nilai *F1-Score* untuk kelas *phone-use distracted driving*.

Dalam konteks deteksi penggunaan ponsel oleh pengemudi, *Macro F1-Score* menjadi penting karena mampu merepresentasikan performa kedua kelas secara lebih seimbang, terutama ketika distribusi data antara kelas *safe driving* dan *phone-use distracted driving* tidak seimbang.

Bab III

Perancangan Sistem


Bab ini menguraikan perancangan sistem deteksi penggunaan ponsel pengemudi berbasis pendekatan *multi-view* dengan *decision-level fusion*. Perancangan mencakup alur sistem secara keseluruhan, pengumpulan dan prapemrosesan data, arsitektur model *single-view*, strategi *decision-level fusion*, serta skenario pengujian dan evaluasi yang digunakan untuk menjawab ketiga rumusan masalah penelitian.

3.1 Alur Penelitian dan Perancangan Sistem

Penelitian ini dirancang secara sistematis melalui serangkaian tahapan untuk mengevaluasi efektivitas pendekatan *multi-view* dan membandingkan strategi *decision-level fusion* dalam mendeteksi penggunaan ponsel oleh pengemudi. Alur perancangan sistem secara keseluruhan dapat dilihat pada Gambar 3.1.

Berdasarkan Gambar 3.1, tahapan perancangan sistem diawali dengan pengumpulan data dari dataset publik 3MDAD [9]. Data yang digunakan dibatasi pada modalitas citra RGB pada kondisi siang hari dari dua sudut pandang, yaitu kamera depan (*front view*) dan kamera samping (*side view*). Setelah data terkumpul, dilakukan seleksi kelas dan perumusan label, kemudian dataset dibagi menjadi himpunan latih, validasi, dan uji menggunakan strategi *subject-based split*. Selanjutnya, setiap partisi melalui tahap prapemrosesan yang mencakup ekstraksi frame, penyesuaian resolusi citra, dan normalisasi.

Setelah data siap, dilakukan pelatihan model klasifikasi *single-view* secara terpisah untuk masing-masing sudut pandang menggunakan arsitektur EfficientNetV2-S [17]. Pada tahap ini, EfficientNetV2-S digunakan sebagai *backbone* dalam model klasifikasi end-to-end, bukan hanya sebagai ekstraktor fitur terpisah. Setiap model menerima citra dari satu sudut pandang dan menghasilkan skor probabilitas untuk dua kelas, yaitu *safe driving* dan *phone-use distracted driving*. Model *single-view* yang dihasilkan kemudian dievaluasi secara mandiri untuk mengidentifikasi tingkat performa dan membedah pola kegagalan (*failure pattern*) yang terjadi ketika sistem hanya mengandalkan satu kamera, terutama pada kondisi oklusi alami.



Gambar 3.1: Diagram alir perancangan sistem

Tahap krusial selanjutnya adalah penerapan pendekatan *multi-view* melalui strategi *decision-level fusion*. Pada tahap ini, skor probabilitas keluaran dari model *front view* dan *side view* digabungkan menggunakan dua strategi yang dibandingkan secara komparatif, yaitu *average fusion* dengan bobot sama rata dan *adaptive fusion* dengan pembobotan dinamis berdasarkan tingkat keyakinan prediksi masing-masing sudut pandang [15, 16]. Tahapan diakhiri dengan evaluasi kinerja sistem secara menyeluruh menggunakan metrik akurasi, presisi, *recall*, dan *Macro F1-Score* untuk menganalisis apakah pendekatan *multi-view* dengan *adaptive fusion* memberikan peningkatan performa dibandingkan *single-view* dan *average fusion* dalam skenario klasifikasi *safe driving* dan *phone-use distracted driving*.

3.2 Pengumpulan dan Prapemrosesan Data

Tahap ini dilakukan untuk menyiapkan data yang digunakan dalam proses pelatihan, validasi, dan pengujian model, mulai dari pengumpulan data hingga prapemrosesan agar sesuai dengan kebutuhan masukan model.

3.2.1 Pengumpulan Data dan Perumusan Label

Penelitian difokuskan pada enam kelas aktivitas, yang terdiri dari satu kelas kontrol yaitu mengemudi aman (A1: *safe driving*), serta lima kelas yang berkaitan dengan penggunaan ponsel (A5–A9: *phone-use distracted driving*) yang mencakup aktivitas menulis pesan, berbicara melalui telepon, dan memotret menggunakan ponsel. Meskipun data yang digunakan berasal dari enam kelas aktivitas pada 3MDAD, tugas klasifikasi dalam penelitian ini dirumuskan sebagai klasifikasi biner. Kelas A1 dipetakan sebagai kelas *safe driving*, sedangkan kelas A5–A9 digabungkan sebagai kelas *phone-use distracted driving*. Perumusan ini disesuaikan dengan fokus penelitian, yaitu membedakan kondisi mengemudi aman dari aktivitas penggunaan ponsel, bukan membedakan jenis aktivitas penggunaan ponsel secara terpisah maupun seluruh bentuk distraksi pengemudi lainnya.

Berdasarkan spesifikasi dataset 3MDAD, total data yang diekstraksi untuk keenam kelas tersebut berjumlah 41.574 pasang *frame* yang tersinkronisasi, atau setara dengan 83.148 citra tunggal dari gabungan *front view* dan *side view*.

Distribusi data berdasarkan label biner menunjukkan bahwa kelas *safe driving* terdiri dari 6.761 pasang *frame*, sedangkan kelas *phone-use distracted driving* yang merupakan gabungan kelas A5–A9 terdiri dari 34.813 pasang *frame*. Dengan demikian, distribusi label pada penelitian ini tidak seimbang karena kelas *phone-use distracted driving* memiliki proporsi yang jauh lebih besar dibandingkan kelas *safe driving*. Rincian distribusi label biner disajikan pada Tabel 3.1.

Tabel 3.1: Distribusi label biner pada data yang digunakan

Label Biner	Kelas Asal	Jumlah Pasang <i>Frame</i>	Proporsi
<i>Safe driving</i>	A1	6.761	16,26%
<i>Phone-use distracted driving</i>	A5–A9	34.813	83,74%
Total	A1, A5–A9	41.574	100%

Ketidakseimbangan distribusi label tersebut menjadi dasar penggunaan *Macro F1-Score* sebagai metrik utama. Metrik ini dipilih karena memberikan bobot evaluasi yang setara terhadap kelas *safe driving* dan *phone-use distracted driving*, sehingga hasil evaluasi tidak didominasi oleh kelas dengan jumlah sampel yang lebih besar.

Untuk memperlihatkan perbedaan informasi visual antara *front view* dan *side view*, contoh pasangan citra dari kelas *safe driving* dan *phone-use distracted driving* ditampilkan pada Gambar 3.2.



Gambar 3.2: Contoh citra dari dataset 3MDAD yang digunakan dalam penelitian ini [9].

Gambar 3.2 menampilkan pasangan *frame* tersinkronisasi dari dua sudut pandang, yaitu *front view* di sebelah kiri dan *side view* di sebelah kanan. Baris pertama menunjukkan kelas mengemudi aman (A1) yang dipetakan sebagai kelas *safe driving*, sedangkan baris kedua menunjukkan contoh aktivitas penggunaan ponsel (A5–A9) yang dipetakan sebagai kelas *phone-use distracted driving*. Perbedaan sudut pandang pada gambar tersebut memperlihatkan

bahwa informasi yang ditangkap oleh *front view* dan *side view* bersifat komplementer, sehingga keduanya dapat digunakan untuk mengevaluasi kontribusi masing-masing sudut pandang maupun untuk mendukung proses *decision-level fusion*.

Karakteristik *multi-view* pada dataset ini memungkinkan analisis kontribusi masing-masing sudut pandang serta penggabungan informasi antar kamera untuk mendukung deteksi aktivitas pengemudi secara lebih komprehensif.

3.2.2 Pembagian Dataset

Pembagian dataset dilakukan menggunakan strategi *subject-based split*, yaitu seluruh sekuens dari satu subjek hanya dimasukkan ke dalam satu partisi saja. Strategi ini digunakan agar model dievaluasi pada subjek yang tidak pernah muncul pada himpunan latih, sehingga risiko kemiripan data antarpartisi dapat diminimalkan. Pendekatan serupa digunakan pada evaluasi *split-by-driver* dalam penelitian deteksi distraksi pengemudi [8].

Secara rancangan, dataset dibagi menggunakan proporsi 70:15:15, yaitu 70% untuk pelatihan, 15% untuk validasi, dan 15% untuk pengujian. Namun, karena pembagian dilakukan berdasarkan subjek dan jumlah subjek pada subset siang hari adalah 50 partisipan, proporsi tersebut dibulatkan pada tingkat subjek menjadi 35 subjek untuk pelatihan, 7 subjek untuk validasi, dan 8 subjek untuk pengujian. Pembagian ini diterapkan secara identik pada data *front view* dan *side view*, sehingga pasangan *frame* dari subjek yang sama tetap berada pada partisi yang sama. Dengan demikian, evaluasi antar sudut pandang dapat berlangsung secara adil dan risiko kebocoran data antar partisi dapat diminimalkan. Rencana pembagian dataset berdasarkan proporsi, jumlah subjek, estimasi pasangan *frame*, dan estimasi citra tunggal disajikan pada Tabel 3.2.

Tabel 3.2: Rencana pembagian dataset menggunakan *subject-based split*

Partisi	Proporsi	Jumlah Subjek	Estimasi Pasang <i>Frame</i>	Estimasi Citra Tunggal
Latih	70%	35	29.102	58.204
Validasi	15%	7	6.236	12.472
Uji	15%	8	6.236	12.472
Total	100%	50	41.574	83.148

Jumlah pasangan *frame* dan citra tunggal pada Tabel 3.2 merupakan estimasi berdasarkan proporsi 70:15:15 dari total 41.574 pasang *frame*. Karena pembagian data dilakukan menggunakan *subject-based split*, jumlah aktual

frame pada setiap partisi dapat sedikit berbeda dari estimasi tersebut, bergantung pada jumlah *frame* yang dimiliki oleh masing-masing subjek. Oleh karena itu, pembagian akhir tetap mengutamakan pemisahan subjek secara konsisten, dengan memastikan seluruh data *front view* dan *side view* dari subjek yang sama berada pada partisi yang sama untuk meminimalkan risiko *data leakage* antarpartisi.

3.2.3 Prapemrosesan Citra

Setiap *frame* dari kedua sudut pandang diproses melalui tahapan berikut. Pertama, *frame* diekstraksi dari setiap sekuens dengan *stride* tertentu untuk mengurangi redundansi temporal antar *frame* yang berdekatan, dengan nilai *stride* ditentukan pada tahap implementasi berdasarkan keseimbangan antara efisiensi komputasi dan keragaman temporal sampel yang dihasilkan. Kedua, setiap *frame* diubah ukurannya menjadi 224×224 piksel sebagai pilihan implementasi untuk menjaga efisiensi komputasi dan keseragaman ukuran masukan. Pemilihan EfficientNetV2-S sebagai *backbone* didasarkan pada karakteristik EfficientNetV2 yang dirancang untuk mencapai keseimbangan antara akurasi, efisiensi parameter, dan kecepatan pelatihan [17]. Ketiga, nilai piksel dinormalisasi menggunakan rata-rata dan standar deviasi ImageNet untuk mendukung *transfer learning* dari bobot pra-latih. Keempat, augmentasi data diterapkan secara eksklusif pada himpunan latih, meliputi *random horizontal flip*, *random rotation*, dan *color jitter*, untuk meningkatkan keragaman sampel dan mengurangi *overfitting*. Himpunan validasi dan uji tidak diberikan augmentasi agar evaluasi mencerminkan performa model pada data asli. Seluruh tahapan prapemrosesan pada masing-masing partisi diterapkan secara identik untuk data *front view* dan *side view*.

3.3 Model *Single-View* Berbasis EfficientNetV2-S

Subbab ini menjelaskan rancangan model klasifikasi *single-view* yang digunakan pada masing-masing sudut pandang. Sesuai perumusan label pada Subbab 3.2.1, setiap model dirancang untuk melakukan klasifikasi biner, yaitu membedakan kelas *safe driving* dan *phone-use distracted driving*. Model *single-view* dibangun menggunakan EfficientNetV2-S sebagai *backbone* utama dan menghasilkan skor probabilitas yang selanjutnya digunakan dalam evaluasi per sudut pandang maupun pada tahap *decision-level fusion*.

3.3.1 Konfigurasi EfficientNetV2-S dan *Classifier Head*

Setiap sudut pandang dimodelkan secara independen menggunakan arsitektur EfficientNetV2-S sebagai *backbone* utama [17]. Dalam penelitian ini, EfficientNetV2-S tidak hanya digunakan sebagai ekstraktor fitur statis, tetapi sebagai bagian dari model klasifikasi *single-view end-to-end* yang dilatih untuk menghasilkan prediksi kelas *safe driving* dan *phone-use distracted driving*.

Dengan demikian, keluaran akhir dari setiap model *single-view* berupa skor probabilitas kelas yang selanjutnya dapat digunakan pada tahap *decision-level fusion*.

Varian EfficientNetV2-S dipilih karena memiliki kompleksitas yang lebih rendah dibandingkan varian EfficientNetV2-M dan EfficientNetV2-L, sehingga beban komputasi dapat dijaga tetap proporsional dalam perbandingan strategi *fusion* [17]. Pemilihan varian ini juga bertujuan agar fokus eksperimen tetap diarahkan pada evaluasi kontribusi sudut pandang dan strategi fusi, bukan pada perbandingan kapasitas arsitektur *backbone*.

Secara umum, arsitektur model *single-view* yang digunakan terdiri dari masukan citra RGB berukuran 224×224 piksel, *backbone* EfficientNetV2-S, *global average pooling*, *dropout*, lapisan *fully connected*, dan aktivasi *softmax*. Lapisan klasifikasi asli EfficientNetV2-S yang digunakan untuk klasifikasi ImageNet diganti dengan *classifier head* baru yang disesuaikan dengan tugas klasifikasi biner pada penelitian ini. Lapisan *dropout* digunakan sebagai teknik regularisasi untuk mengurangi risiko *overfitting*, sedangkan lapisan *fully connected* menghasilkan dua unit keluaran yang merepresentasikan kelas *safe driving* dan *phone-use distracted driving*.

3.3.2 Skema *Transfer Learning* dan *Fine-Tuning*

Model diinisialisasi menggunakan bobot pra-latih ImageNet (*ImageNet pre-trained weights*) sebagai bentuk *transfer learning*. Selanjutnya, model dilatih menggunakan skema *fine-tuning* pada dataset 3MDAD agar representasi fitur yang telah dipelajari dari ImageNet dapat disesuaikan dengan domain citra pengemudi di dalam kabin kendaraan.

Pada tahap implementasi, lapisan klasifikasi bawaan EfficientNetV2-S diganti dengan *classifier head* baru untuk dua kelas keluaran. Detail teknis seperti *learning rate*, *batch size*, jumlah epoch maksimum, nilai *dropout*, serta pengaturan jumlah lapisan yang dibekukan atau dilatih kembali akan ditentukan berdasarkan hasil eksplorasi awal. Dengan pendekatan ini, rancangan model tetap fleksibel terhadap kebutuhan implementasi tanpa mengubah tujuan utama penelitian, yaitu mengevaluasi kontribusi sudut pandang dan strategi *fusion*.

3.3.3 Pelatihan dan Keluaran Model *Single-View*

Arsitektur yang identik diterapkan pada dua model yang berbeda, yaitu model *front view* (M_{front}) dan model *side view* (M_{side}). Kedua model tersebut dilatih secara independen menggunakan data dari sudut pandang masing-masing. Model M_{front} hanya menerima citra dari kamera depan, sedangkan model M_{side} hanya menerima citra dari kamera samping. Dengan rancangan ini, performa masing-masing sudut pandang dapat dianalisis secara terpisah sebelum kedua skor probabilitasnya digabungkan pada tahap *decision-level fu-*

sion.

Pada tahap pelatihan, model dioptimasi menggunakan fungsi kerugian *cross-entropy loss*, karena tugas yang dilakukan merupakan klasifikasi dua kelas dengan keluaran *softmax*. Fungsi kerugian tersebut digunakan untuk mengukur perbedaan antara prediksi model dan label sebenarnya, sehingga bobot model dapat diperbarui selama proses pelatihan.

Keluaran model dinyatakan sebagai skor probabilitas melalui fungsi *softmax*. Untuk setiap citra masukan, model menghasilkan dua nilai probabilitas, yaitu probabilitas kelas *safe driving* dan probabilitas kelas *phone-use distracted driving*. Dalam tahap evaluasi dan *fusion*, skor probabilitas kelas *phone-use distracted driving* digunakan sebagai dasar pengambilan keputusan. Prediksi dikategorikan sebagai *phone-use distracted driving* apabila skor probabilitas kelas *phone-use distracted driving* bernilai lebih besar atau sama dengan ambang batas 0,5. Ambang batas yang sama digunakan pada seluruh konfigurasi pengujian agar evaluasi antara model *single-view* dan *multi-view* tetap konsisten.

Setelah proses pelatihan selesai, masing-masing model *single-view* dievaluasi secara mandiri untuk mengidentifikasi perbedaan performa serta pola kegagalan antar sudut pandang, khususnya pada kondisi oklusi alami yang menjadi tantangan utama sistem *single-view* [10, 11].

3.3.4 Algoritma Sistem

Algoritma 1 merangkum alur kerja sistem yang diusulkan, mulai dari pelatihan model *single-view* berbasis EfficientNetV2-S pada masing-masing sudut pandang, pembentukan skor probabilitas kelas *phone-use distracted driving*, hingga penggabungan keputusan menggunakan strategi *decision-level fusion*. Algoritma ini ditempatkan pada bagian model untuk memperjelas hubungan antara arsitektur *single-view*, keluaran probabilitas, dan mekanisme fusi yang digunakan dalam sistem.

Algorithm 1 Alur Sistem Klasifikasi *safe driving* dan *phone-use distracted driving* Berbasis *Multi-View*

1: **procedure** DRIVERPHONEDETECTION($\mathcal{D}_{\text{front}}, \mathcal{D}_{\text{side}}, F$)
Require: Dataset $\mathcal{D}_{\text{front}}$ dan $\mathcal{D}_{\text{side}}$, serta strategi fusi $F \in \{\text{average}, \text{adaptive}\}$
Ensure: Prediksi akhir $\hat{y}$ dan metrik evaluasi sistem
2: Bagi $\mathcal{D}_{\text{front}}$ dan $\mathcal{D}_{\text{side}}$ menjadi data latih, validasi, dan uji menggunakan *subject-based split*

Tahap pelatihan model *single-view*

3: **for** setiap $\text{view} \in \{\text{front}, \text{side}\}$ **do**
4: Inisialisasi M_{view} dengan EfficientNetV2-S dan bobot pra-latih ImageNet
5: Ganti *classifier head* untuk dua kelas: *safe driving* dan *phone-use distracted driving*
6: Latih M_{view} pada $\mathcal{D}_{\text{view}}^{\text{train}}$ menggunakan *cross-entropy loss*
7: Validasi M_{view} pada $\mathcal{D}_{\text{view}}^{\text{val}}$
8: Simpan model terbaik sebagai M_{view}^*
9: **end for**

Tahap inferensi dan *decision-level fusion*

10: **for** setiap pasangan sampel uji ke- i **do**
11: Hitung probabilitas kelas *phone-use distracted driving* dari masing-masing model:
 $P_{\text{front}}^{(i)} \leftarrow P(\text{phone-use distracted driving} \mid x_{\text{front}}^{(i)}; M_{\text{front}}^*)$
 $P_{\text{side}}^{(i)} \leftarrow P(\text{phone-use distracted driving} \mid x_{\text{side}}^{(i)}; M_{\text{side}}^*)$
12: **if** $F = \text{average}$ **then**
13: Hitung skor gabungan: $P_{\text{fused}}^{(i)} \leftarrow (P_{\text{front}}^{(i)} + P_{\text{side}}^{(i)})/2$
14: **else if** $F = \text{adaptive}$ **then**
15: Hitung *confidence* tiap *view*: $c_k^{(i)} \leftarrow |P_k^{(i)} - 0,5|$
16: Hitung bobot adaptif $w_k^{(i)}$ menggunakan *softmax* terhadap $c_k^{(i)}$
17: Hitung skor gabungan: $P_{\text{fused}}^{(i)} \leftarrow w_{\text{front}}^{(i)} P_{\text{front}}^{(i)} + w_{\text{side}}^{(i)} P_{\text{side}}^{(i)}$
18: **end if**
19: **if** $P_{\text{fused}}^{(i)} \geq 0,5$ **then**
20: $\hat{y}^{(i)} \leftarrow \text{phone-use distracted driving}$
21: **else**
22: $\hat{y}^{(i)} \leftarrow \text{safe driving}$
23: **end if**
24: **end for**

Tahap evaluasi

25: Hitung akurasi, presisi, *recall*, *Macro F1-Score*, dan *confusion matrix*
26: **end procedure**

3.4 Strategi *Decision-Level Fusion*

Setelah kedua model *single-view* selesai dilatih, skor probabilitas kelas positif (*phone-use distracted driving*) dari M_{front} dan M_{side} digabungkan menggunakan dua strategi *decision-level fusion* yang dibandingkan secara langsung. Penggabungan dilakukan pada tingkat keputusan karena input yang digunakan pada tahap ini bukan lagi fitur visual dari *backbone*, melainkan skor probabilitas keluaran dari masing-masing model *single-view*.

3.4.1 *Average Fusion*

Pada strategi *average fusion*, skor probabilitas kelas positif dari kedua model digabungkan dengan bobot yang sama rata. Skor gabungan P_{avg} dinyatakan sebagai:

$$P_{\text{avg}} = \frac{P_{\text{front}} + P_{\text{side}}}{2} \quad (3.1)$$

di mana P_{front} dan P_{side} adalah skor probabilitas kelas positif dari masing-masing model. Prediksi akhir ditetapkan sebagai kelas positif apabila $P_{\text{avg}} \geq 0,5$. Ambang batas 0,5 digunakan sebagai keputusan desain eksperimen untuk menjaga konsistensi evaluasi antara model *single-view*, *average fusion*, dan *adaptive fusion*. Pendekatan ini bersifat statis karena tidak mempertimbangkan perbedaan kualitas prediksi antar kamera pada setiap sampel. Roitberg dkk. [15] menunjukkan bahwa *average fusion* tidak selalu menjadi pilihan yang paling optimal karena memperlakukan kontribusi setiap sumber secara setara tanpa menilai tingkat kepercayaan prediksinya.

3.4.2 *Adaptive Fusion*

Pada strategi *adaptive fusion*, bobot setiap model ditentukan secara dinamis berdasarkan tingkat kepercayaan (*confidence*) prediksinya. Tingkat kepercayaan model ke- k pada sampel ke- i didefinisikan sebagai jarak skor probabilitas terhadap ambang batas keputusan:

$$c_k^{(i)} = \left| P_k^{(i)} - 0,5 \right| \quad (3.2)$$

Bobot ternormalisasi untuk masing-masing model dihitung menggunakan *softmax* atas nilai kepercayaan tersebut:

$$w_k^{(i)} = \frac{\exp(c_k^{(i)})}{\sum_{j \in \{\text{front}, \text{side}\}} \exp(c_j^{(i)})} \quad (3.3)$$

Skor gabungan *adaptive fusion* kemudian dinyatakan sebagai:

$$P_{\text{adp}}^{(i)} = w_{\text{front}}^{(i)} \cdot P_{\text{front}}^{(i)} + w_{\text{side}}^{(i)} \cdot P_{\text{side}}^{(i)} \quad (3.4)$$

dengan i menyatakan indeks sampel uji, k menyatakan sudut pandang yang sedang dihitung, yaitu *front* atau *side*, dan j menyatakan indeks penjumlahan pada proses normalisasi *softmax*. Nilai $P_{\text{front}}^{(i)}$ dan $P_{\text{side}}^{(i)}$ masing-masing menyatakan skor probabilitas kelas *phone-use distracted driving* dari model *front view* dan *side view*, sedangkan $w_{\text{front}}^{(i)}$ dan $w_{\text{side}}^{(i)}$ menyatakan bobot adaptif untuk masing-masing sudut pandang.

Prediksi akhir ditetapkan sebagai kelas positif apabila $P_{\text{adp}}^{(i)} \geq 0,5$, mengikuti konvensi yang sama dengan strategi *average fusion*. Mekanisme ini mengadaptasi gagasan umum pembobotan dinamis dari *Adaptive Temporal Fusion Module* (ATFM) yang diusulkan oleh Lv dkk. [16]. Perbedaannya, ATFM digunakan untuk menggabungkan informasi temporal antar-*frame* dalam satu kamera, sedangkan penelitian ini menerapkan pembobotan berbasis tingkat keyakinan pada dimensi spasial lintas-kamera (*multi-view*). Dengan demikian, mekanisme *adaptive fusion* pada penelitian ini tidak dimaksudkan sebagai replikasi penuh ATFM, melainkan sebagai adaptasi prinsip pembobotan berbasis tingkat keyakinan prediksi untuk penggabungan skor antar sudut pandang. Model yang menghasilkan prediksi lebih meyakinkan pada suatu sampel akan memperoleh bobot lebih besar. Namun, efektivitas mekanisme ini tetap perlu dibuktikan melalui evaluasi empiris karena prediksi dengan tingkat keyakinan tinggi tidak selalu menunjukkan prediksi yang benar.

3.5 Skenario Pengujian dan Evaluasi

Tahap ini dilakukan untuk menguji dan membandingkan performa model berdasarkan skenario pengujian dan metrik evaluasi yang telah ditentukan.

3.5.1 Skenario Pengujian

Skenario pengujian dalam penelitian ini disusun secara bertahap untuk menggambarkan alur eksperimen sejak pembentukan model dasar hingga evaluasi strategi *fusion*. Untuk menjawab ketiga rumusan masalah penelitian, skenario pengujian terdiri dari empat tahap sebagai berikut.

Tahap 1: *Fine-tuning model single-view*. Pada tahap ini, EfficientNetV2-S yang telah diinisialisasi dengan bobot pra-latih ImageNet dilatih secara terpisah pada data *front view* dan *side view*. Proses ini menghasilkan dua model dasar, yaitu M_{front} dan M_{side} , yang masing-masing merepresentasikan model klasifikasi dari satu sudut pandang. Tahap *fine-tuning* tidak diperlakukan sebagai konfigurasi pembandingan akhir, melainkan sebagai proses pembentukan model *single-view* yang digunakan pada tahap evaluasi berikutnya.

Tahap 2: Evaluasi model *single-view*. Model M_{front} dan M_{side} dievaluasi secara independen pada himpunan uji untuk mengukur performa masing-masing sudut pandang dalam membedakan kondisi *safe driving* dan *phone-use distracted driving*. Hasil evaluasi dari kedua model tersebut dibandingkan untuk menganalisis perbedaan performa dan pola kegagalan deteksi antara *front view* dan *side view*. Model dengan *Macro F1-Score* tertinggi ditetapkan sebagai sistem *single-view* terbaik dan dijadikan *baseline* untuk perbandingan dengan pendekatan *multi-view*. Selain evaluasi kuantitatif, analisis kualitatif dilakukan terhadap *confusion matrix* dan sampel salah klasifikasi dari masing-masing sudut pandang untuk mengidentifikasi pola kegagalan deteksi pada kondisi oklusi.

Tahap 3: Evaluasi *multi-view* dengan *average fusion*. Pada tahap ini, skor probabilitas kelas *phone-use distracted driving* dari M_{front} dan M_{side} digabungkan menggunakan strategi *average fusion* sesuai Persamaan 3.1. Hasil penggabungan tersebut digunakan untuk menghasilkan keputusan akhir sistem dan dibandingkan dengan model *single-view* terbaik sebagai *baseline*.

Tahap 4: Evaluasi *multi-view* dengan *adaptive fusion*. Pada tahap ini, skor probabilitas kelas *phone-use distracted driving* dari M_{front} dan M_{side} digabungkan menggunakan strategi *adaptive fusion* sesuai Persamaan 3.4. Strategi ini digunakan untuk mengevaluasi apakah pembobotan dinamis berdasarkan tingkat keyakinan prediksi dapat memberikan performa yang lebih baik dibandingkan *average fusion* maupun model *single-view* terbaik.

Karena kelas *phone-use distracted driving* berasal dari gabungan lima kelas aktivitas (A5–A9), sedangkan kelas *safe driving* hanya berasal dari satu kelas aktivitas (A1), distribusi data pada penelitian ini tidak seimbang. Oleh karena itu, *Macro F1-Score* digunakan sebagai metrik utama karena memberikan bobot evaluasi yang setara terhadap kedua kelas, sedangkan akurasi, presisi, dan *recall* digunakan sebagai metrik pendukung. Selain itu, *confusion matrix* dan sampel salah klasifikasi dianalisis untuk mengamati kecenderungan kesalahan prediksi pada masing-masing kelas.

3.5.2 Metrik Evaluasi

Evaluasi dilakukan terhadap model *single-view* dari masing-masing sudut pandang serta pendekatan *multi-view* dengan *average fusion* dan *adaptive fusion* menggunakan metrik akurasi, presisi, *recall*, dan *Macro F1-Score* yang telah didefinisikan pada Bab II [24]. Penggunaan metrik tersebut diperlukan agar performa sistem dapat dianalisis secara lebih menyeluruh, khususnya karena kelas *phone-use distracted driving* merupakan gabungan dari beberapa kelas aktivitas dan memiliki jumlah sampel yang lebih besar dibandingkan kelas *safe driving*. Dalam penelitian ini, *Macro F1-Score* digunakan sebagai metrik utama, sedangkan akurasi, presisi, dan *recall* digunakan sebagai metrik pendukung. Selain evaluasi kuantitatif, analisis *confusion matrix* dilakukan

pada setiap konfigurasi evaluasi untuk membedah pola kesalahan klasifikasi secara lebih mendalam. Sampel salah klasifikasi dianalisis secara visual untuk mengidentifikasi kemungkinan penyebab kesalahan, seperti oklusi tangan atau perangkat ponsel, posisi tubuh pengemudi, keterbatasan sudut pandang kamera, atau kemiripan visual antara kondisi *safe driving* dan *phone-use distracted driving*.

Pada penelitian ini, kelas positif didefinisikan sebagai *phone-use distracted driving*, sedangkan kelas negatif didefinisikan sebagai *safe driving*. Dengan demikian, *false negative* menunjukkan kondisi penggunaan ponsel yang gagal terdeteksi sebagai distraksi, sedangkan *false positive* menunjukkan kondisi mengemudi aman yang keliru diprediksi sebagai penggunaan ponsel. Interpretasi ini digunakan dalam analisis *confusion matrix* dan sampel salah klasifikasi.

Daftar Pustaka

- [1] D. Tan, W. Tian, C. Wang, L. Chen, and L. Xiong, “Driver distraction behavior recognition for autonomous driving: Approaches, datasets and challenges,” *IEEE Transactions on Intelligent Vehicles*, 2024.
- [2] H. V. Koay, J. H. Chuah, C.-O. Chow, and Y.-L. Chang, “Detecting and recognizing driver distraction through various data modality using machine learning: A review, recent advances, simplified framework and open challenges (2014–2021),” *Engineering Applications of Artificial Intelligence*, vol. 115, p. 105309, 2022.
- [3] T. Huang, R. Fu, and Q. Sun, “Driver’s mobile phone usage detection using guided learning based on attention features and prior knowledge,” *Expert Systems with Applications*, vol. 206, p. 117877, 2022.
- [4] G. Caiza, A. Guanuche, and C. Villafuerte, “Detection of mobile phone use while driving supported by artificial intelligence,” *Applied Sciences*, vol. 16, no. 2, p. 675, 2026.
- [5] A. A. Mohammed, X. Geng, J. Wang, and Z. Ali, “Driver distraction detection using semi-supervised lightweight vision transformer,” *Engineering Applications of Artificial Intelligence*, vol. 129, p. 107618, 2024.
- [6] T. Khan, G. Choi, and S. Lee, “Effnet-ca: An efficient driver distraction detection based on multiscale feature extractions and channel attention mechanism,” *Sensors*, vol. 23, no. 8, p. 3835, 2023.
- [7] W. Xiao, H. Liu, Z. Ma, and W. Chen, “Attention-based deep neural network for driver behavior recognition,” *Future Generation Computer Systems*, vol. 132, pp. 152–161, 2022.
- [8] H. Gao and Y. Liu, “Improving real-time driver distraction detection via constrained attention mechanism,” *Engineering Applications of Artificial Intelligence*, vol. 128, p. 107408, 2024.
- [9] I. Jegham, A. B. Khalifa, I. Alouani, and M. A. Mahjoub, “A novel public dataset for multimodal multiview and multispectral driver distraction

- analysis: 3mdad,” *Signal Processing: Image Communication*, vol. 88, p. 115960, 2020.
- [10] C.-H. Hsia, L.-Y. Ke, S.-T. Chen, and Y.-C. He, “Distracted driving behavior recognition system based on deep learning approach and multi-view imaging,” *IEEE Access*, vol. 14, pp. 8107–8115, 2026.
 - [11] J. Kuang, W. Li, F. Li, J. Zhang, and Z. Wu, “Mifi: Multi-camera feature integration for robust 3d distracted driver activity recognition,” *IEEE Transactions on Intelligent Transportation Systems*, vol. 25, no. 1, pp. 338–348, 2023.
 - [12] Y. Ma, V. Sanchez, S. Nikan, D. Upadhyay, B. Atote, and T. Guha, “Robust multiview multimodal driver monitoring system using masked multi-head self-attention,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023, pp. 2617–2625.
 - [13] X. Yang, Y. Qiao, S. Han, Z. Feng, and Y. Chen, “Appearance-posture fusion network for distracted driving behavior recognition,” *Expert Systems with Applications*, vol. 257, p. 124883, 2024.
 - [14] R. Vijeikis, I. D. Dada, A. A. Abayomi-Alli, and V. Raudonis, “Enhancing driver monitoring systems based on novel multi-task fusion algorithm,” *Sensors*, vol. 25, no. 21, p. 6799, 2025.
 - [15] A. Roitberg, K. Peng, Z. Marinov, C. Seibold, D. Schneider, and R. Stiefelhagen, “A comparative analysis of decision-level fusion for multimodal driver behaviour understanding,” in *2022 IEEE intelligent vehicles symposium (IV)*. IEEE, 2022, pp. 1438–1444.
 - [16] X. Lv, G. Zheng, H. Zhai, K. Zhou, and W. Zhang, “Driver fatigue detection method based on temporal-spatial adaptive networks and adaptive temporal fusion module,” *Computers and Electrical Engineering*, vol. 119, p. 109540, 2024.
 - [17] M. Tan and Q. Le, “Efficientnetv2: Smaller models and faster training,” in *Proceedings of the International Conference on Machine Learning (ICML)*. PMLR, 2021, pp. 10 096–10 106.
 - [18] C. Duan, Y. Gong, J. Liao, M. Zhang, and L. Cao, “Frnet: Dcnn for real-time distracted driving detection toward embedded deployment,” *IEEE Transactions on Intelligent Transportation Systems*, vol. 24, no. 9, pp. 9835–9848, 2023.

- [19] C. Duan, Z. Liu, J. Xia, M. Zhang, J. Liao, and L. Cao, “Enhancing cross-dataset performance of distracted driving detection with score softmax classifier and dynamic gaussian smoothing supervision,” *IEEE Transactions on Intelligent Vehicles*, vol. 10, no. 1, pp. 282–295, 2025.
- [20] S. B. Sukhavasi, S. B. Sukhavasi, K. Elleithy, A. El-Sayed, and A. Elleithy, “Deep neural network approach for pose, illumination, and occlusion invariant driver emotion detection,” *International Journal of Environmental Research and Public Health*, vol. 19, no. 4, p. 2352, 2022.
- [21] Y. Xu, S. Jiang, Z. Cui, and F. Su, “Multi-view action recognition for distracted driver behavior localization,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024, pp. 7172–7179.
- [22] L. Mou, J. Chang, C. Zhou, Y. Zhao, N. Ma, B. Yin, R. Jain, and W. Gao, “Multimodal driver distraction detection using dual-channel network of cnn and transformer,” *Expert Systems with Applications*, vol. 234, p. 121066, 2023.
- [23] M. Tan and Q. Le, “Efficientnet: Rethinking model scaling for convolutional neural networks,” in *Proceedings of the International Conference on Machine Learning (ICML)*. PMLR, 2019, pp. 6105–6114.
- [24] O. Rainio, J. Teuho, and R. Klén, “Evaluation metrics and statistical tests for machine learning,” *Scientific reports*, vol. 14, no. 1, p. 6086, 2024.
- [25] I. M. De Diego, A. R. Redondo, R. R. Fernández, J. Navarro, and J. M. Moguerza, “General performance score for classification problems: Im de diego et al.” *Applied Intelligence*, vol. 52, no. 10, pp. 12 049–12 063, 2022.

Lampiran